

Rastreamento de Objetos Baseado em Casamento de Padrões (Template Matching): Uma Abordagem Simplória utilizando OpenCV

Herton Silveira¹, Diogo Silva de Carvalho¹, Andre Vinicius Trentini¹

Professor Orientador: Gilmário Barbosa dos Santos

Abstract. *This article describes the implementation and analysis of a simple object tracking strategy in video using Template Matching techniques available in the OpenCV library. From a short video containing 300 frames, with a static camera and no autofocus, the first frame was extracted and a region of interest (ROI) was cropped as a template. Six matching methods (TM_SQDIFF, TM_SQDIFF_NORMED, TM_CCORR, TM_CCORR_NORMED, TM_CCOEFF, and TM_CCOEFF_NORMED) were tested to identify the target in each frame. The analysis revealed that the TM_CCOEFF_NORMED method has the best discrimination capacity and stability for the scene in question.*

Resumo. *Este artigo descreve a implementação e análise de uma estratégia simples de rastreamento de objetos em vídeo utilizando técnicas de Template Matching (casamento de padrões) disponíveis na biblioteca OpenCV. A partir de um vídeo curto contendo 300 quadros, com câmera estática e sem autofoco, foi extraído o primeiro quadro e recortada uma região de interesse (ROI) como template. Seis métodos de matching (TM_SQDIFF, TM_SQDIFF_NORMED, TM_CCORR, TM_CCORR_NORMED, TM_CCOEFF e TM_CCOEFF_NORMED) foram testados para identificar o alvo em cada quadro. Os resultados foram tabelados e plotados graficamente, sendo as métricas comparadas por meio de estatística descritiva (média, desvio padrão e coeficiente de variação). A análise revelou que o método TM_CCOEFF_NORMED possui a melhor capacidade de discriminação e estabilidade para a cena em questão e, por isso, foi o método escolhido para gerar o vídeo de saída com o rastreo marcado.*

1 Introdução

O rastreamento de objetos em sequências de imagens (*surveillance* / monitoramento) é uma tarefa fundamental em visão computacional. Consiste em determinar a trajetória e garantir a identificação de um ou mais objetos ao longo do tempo. Existem diversas abordagens consolidadas para obter um rastreo, tais como o uso do fluxo ótico na estimativa de movimento ou detectores robustos de características (SURF, ORB, BRIEF).

No entanto, uma forma inicial e bastante didática de se realizar um rastreo é aplicar uma técnica de detecção de Regiões de Interesse (ROI - *Regions of Interest*) através da avaliação de casamento (*matching*) de um padrão (*template*) isolado na primeira cena em relação a cada um dos quadros subsequentes de um vídeo. O objetivo deste trabalho é exercitar o método de *Template Matching* por meio da biblioteca OpenCV (`cvMatchTemplate`), comparar e interpretar as diferentes abordagens matemáticas disponíveis na biblioteca e eleger a melhor para construir um algoritmo de rastreamento funcional.

2 Fundamentação Teórica

A essência do *Template Matching* baseia-se em deslizar um recorte de padrão (*template*) de dimensões $w \times h$ sobre uma imagem original e realizar o cômputo matemático em cada posicionamento possível para definir o “casamento”. O OpenCV gerencia essa tarefa através da função `cv2.matchTemplate()`. O resultado dessa função é um mapa em tons de cinza descrevendo o quão semelhante uma sub-região da imagem é ao *template*.

Existem diversas estratégias para calcular essa relação:

- **Diferença Quadrada (TM_SQDIFF e TM_SQDIFF_NORMED):** A função calcula a diferença ao quadrado entre os pixels do template e os da imagem. Sendo uma medida de distância, o melhor casamento é o valor mais baixo possível (tendendo a zero).
- **Correlação Cruzada (TM_CCORR e TM_CCORR_NORMED):** A função multiplica de maneira cruzada as intensidades dos pixels. Valores altos indicam excelentes casamentos.
- **Coefficiente de Correlação (TM_CCOEFF e TM_CCOEFF_NORMED):** O método também realiza multiplicação cruzada, mas realiza a subtração da média previamente (*mean-removed*). Consequentemente, um casamento perfeito atinge o valor máximo disponível, um mau casamento tem valor nulo, e uma correspondência perfeitamente invertida apresenta um valor negativo.

As versões normalizadas (NORMED) dessas equações reajustam os dados resultantes para o intervalo genérico de $[0, 1]$ ou $[-1, 1]$. Essa técnica facilita a interpretação em qualquer ambiente de iluminação e permite a configuração de limiares automáticos e generalistas.

3 Metodologia

Para o projeto simulado de rastreamento, os seguintes processos foram conduzidos através de código na linguagem Python em associação aos métodos do OpenCV:

1. **Captura do Vídeo:** Foi desenvolvido e utilizado um vídeo caseiro contemplando aproximadamente 300 quadros. O deslocamento do objeto ocorreu vagarosamente frente a um fundo estático e inalterado.
2. **Separação de Quadros:** Os quadros individuais do vídeo foram segmentados e convertidos para o formato de tons de cinza, resultando nas imagens individuais em disco.

Exemplos de quadros capturados ao longo do tempo da gravação original podem ser observados na Figura 1.




Figura 1: Quadro Inicial, Quadro Intermediário e Quadro Final.

3. **Obtenção do Template:** Mediante interatividade providenciada pela função `cv2.selectROI`, selecionou-se manualmente uma amostra na primeira imagem contemplando o enquadramento ideal do objeto a ser rastreado, definindo assim o template base.
4. **Aplicação dos Métodos de Matching:** Aplicou-se um iterador em todos os quadros e testou-se cada um dos seis métodos. Capturaram-se os menores e maiores valores resultantes através do método `cv2.minMaxLoc()`.
5. **Geração de Análise:** As referências coletadas foram ordenadas e salvas em planilhas CSV e traçadas em gráficos para elucidação de desempenho.
6. **Vídeo Resultante:** Uma vez selecionado o algoritmo de maior confiabilidade, gerou-se um arquivo final no formato MP4 desenhando-se as caixas de identificação para demarcar a silhueta encontrada ao longo do trajeto no vídeo.

4 Resultados e Discussão

Para avaliar a assertividade de cada estratégia, traçou-se e exportou-se os valores limítrofes encontrados durante todos os 300 quadros de simulação para cada método. As figuras a seguir representam visualmente as avaliações de respostas extremas das funções.




Figura 2: Diferença Quadrada (Esquerda) e Diferença Quadrada Normalizada (Direita).




Figura 3: Correlação Cruzada (Esquerda) e Correlação Cruzada Normalizada (Direita).




Figura 4: Coeficiente de Correlação (Esquerda) e Coeficiente Normalizado (Direita).

Foi processada a análise estatística sobre o volume de dados resgatados das planilhas CSV, obtendo-se o quadro comparativo descrito na Tabela 1.

Tabela 1: Resultados Estatísticos dos Métodos Avaliados

Método	Métrica usada	Média	Desvio padrão	CV (%)	Faixa de valores
TM_CCOEFF	max_val	$5,26 \times 10^7$	$3,15 \times 10^6$	6,0	não normalizado
TM_CCOEFF_NORMED	max_val	0,861	0,064	7,5	[-1, 1]
TM_CCORR	max_val	$2,97 \times 10^8$	$5,72 \times 10^6$	1,9	não normalizado
TM_CCORR_NORMED	max_val	0,949	0,026	2,7	[0, 1]
TM_SQDIFF	min_val	1.89×10^7	1.14×10^7	60,0	não normalizado
TM_SQDIFF_NORMED	min_val	0,118	0,068	58,2	[0, 1]

4.1 Análise e Justificativa de Melhor Método

Métodos de Diferença Quadrada (TM_SQDIFF e TM_SQDIFF_NORMED): Estes métodos apresentaram o maior coeficiente de variação ($\approx 60\%$), perceptível também pelos ruídos irregulares plotados na linha de valor mínimo em seus respectivos gráficos. Isto sinaliza uma altíssima sensibilidade a qualquer mudança singela do cenário. Por carecer de ajustes de normalização no contraste da matriz analítica, são altamente afetados pelas variações de brilho entre os quadros.

Métodos de Correlação (TM_CCORR E TM_CCORR_NORMED): Exibiram a menor variação entre todos do experimento ($\approx 2\% - 3\%$). Porém, este comportamento aparentemente estável reflete sua ineficiência central: métodos puros de correlação cruzada não realizam subtração das médias do entorno. Desse modo, o valor obtido é corrompido por regiões de brilho exagerado, inviabilizando a avaliação real dos contornos do objeto.

Métodos de Coeficiente de Correlação (TM_CCOEFF e TM_CCOEFF_NORMED): Este grupo ofereceu maior equilíbrio para o projeto. Por subtraírem a média de luminância das superfícies antes de correlacioná-las pontualmente, resultam em robustez contra cenários instáveis e reflexos inconstantes. O TM_CCOEFF_NORMED espelha o Coeficiente de Correlação de Pearson, facilitando sobremaneira estipular barreiras seguras na análise do sistema.

Sendo assim, o TM_CCOEFF_NORMED foi atestado como a vertente de maior confiabilidade na tarefa e foi o algoritmo selecionado para processar a re-construção das marcações de limite no objeto alvo renderizadas no arquivo audiovisual conclusivo.

5 Conclusão

O procedimento delineado nesta pesquisa permitiu realizar e comparar sistematicamente abordagens basilares de rastreamento contínuo em vídeo a partir da manipulação do OpenCV no

ecossistema de Python. O experimento apontou na prática que algoritmos de Template Matching não subtraídos de sua média local sucumbem facilmente aos níveis flutuantes de energia luminosa. Por outro lado, a detecção refinada por métricas correlacionais normalizadas revelou um processamento preciso, seguro e de fácil delimitação parametrizada, evidenciando sua capacidade educacional e funcionalidade objetiva no campo da Visão Computacional.

Referências

- [1] OPENCV. *Template Matching*. Documentation. Disponível em: https://docs.opencv.org/4.5.2/d4/dc6/tutorial_py_template_matching.html. Acesso em: 20 Set. 2026.
- [2] OPENCV. *Template Matching (3.4)*. Documentation. Disponível em: https://docs.opencv.org/3.4/de/da9/tutorial_template_matching.html. Acesso em: 20 Set. 2026.
- [3] SANTOS, Gilmário Barbosa dos. *Rastreio usando matching template*. Material didático disponibilizado em formato PDF - Aula de PIM.